

Relatório EDA — I2A2

Usuário: leandro.vidigal@outlook.com

Dataset: creditcard.csv

Gerado em: 26/09/2025 23:56:16

Framework escolhida para este agente:

Frontend: Streamlit. Análises: Pandas/NumPy/Matplotlib/Seaborn. IA: LangChain + OpenAI (ChatOpenAI) para insights detalhados, com memória por usuário (JSON em 'memories/'). PDF: reportlab (preferencial) ou fpdf2 (fallback).

1. Pergunta

Detecte outliers em V1 e me explique

Tipo de análise: box — Pedido de outliers/anomalias.

Colunas usadas: V1

Insights


Aqui estão os pontos sobre a detecção de outliers na coluna V1 do dataset, com base nas informações fornecidas:

1. ****Total de Linhas****: O dataset contém 284.807 linhas, das quais 7062 (aproximadamente 2,48%) foram identificadas como outliers na coluna V1.
2. ****Taxa de Fraude****: A taxa de fraudes no dataset é de 0,17% (492 fraudes em 284.807 transações), o que indica que a maioria das transações (99,83%) é legítima.
3. ****Identificação de Outliers****: Os outliers em V1 foram identificados utilizando o método do boxplot, que considera valores que estão além de 1,5 vezes o intervalo interquartil (IQR) como outliers.
4. ****Distribuição de V1****: A análise da distribuição de V1 mostra que a maioria dos valores está concentrada em uma faixa específica, enquanto os outliers se afastam significativamente dessa faixa, indicando possíveis anomalias.
5. ****Comparação com Dados Anteriores****: Em análises anteriores, a detecção de outliers em colunas numéricas similares resultou em taxas de outliers variando entre 1% a 3%, sugerindo que a coluna V1 está dentro de uma faixa esperada, mas com uma quantidade considerável de outliers.
6. ****Impacto dos Outliers****: A presença de 7062 outliers pode impactar negativamente modelos preditivos, pois eles podem distorcer a média e a variância, levando a decisões erradas em relação à detecção de fraudes.
7. ****Análise de Tendências****: A análise temporal (coluna Time) pode ser realizada para verificar se os outliers em V1 estão concentrados em períodos específicos, o que pode indicar padrões de comportamento fraudulentos.
8. ****Ações Recomendadas****: Recomenda-se investigar os outliers identificados em V1 para entender se são transações fraudulentas ou se representam comportamentos legítimos, a fim de ajustar os modelos de detecção de fraudes.
9. ****Visualização****: A visualização em boxplot da coluna V1 pode ajudar a ilustrar a distribuição dos dados e a localização dos outliers, facilitando a comunicação dos resultados para as partes interessadas.

10. ****Próximos Passos****: Considerar a aplicação de técnicas de machine learning, como Isolation Forest ou DBSCAN, para uma análise mais robusta dos outliers e sua relação com a classe de fraude.
11. ****Validação Cruzada****: Realizar validação cruzada com outros conjuntos de dados para verificar a consistência dos outliers identificados e sua relação com fraudes conhecidas.
12. ****Documentação****: Manter um registro detalhado das análises de outliers e suas implicações para futuras referências e para a melhoria contínua dos processos de detecção de fraudes.

Métricas calculadas (baseadas no CSV)

```
{
"colunas": [
"V1"
],
"outliers_por_coluna": {
"V1": 7062
}
}
```



2. Pergunta

Existem padrões temporais em 'Time' vs 'Class'?

Tipo de análise: temporal — Pergunta temporal detectada (ex.: padrões em fraudes ao longo do tempo).

Colunas usadas: Time

Insights

Aqui estão os pontos sobre a análise de padrões temporais na coluna 'Time' em relação à classe de fraude ('Class') no dataset:

1. ****Total de Transações****: O dataset contém 284.807 transações, das quais 492 (0,17%) são classificadas como fraudulentas, resultando em uma taxa de fraude de 0,0017.
2. ****Média da Taxa de Fraude****: A média da taxa de fraude ao longo do tempo é de aproximadamente 0,28% (0,0028), indicando que, em média, uma em cada 357 transações é fraudulenta.
3. ****Pico de Taxa de Fraude****: O pico da taxa de fraude registrado é de 5,85% (0,0585), sugerindo que em determinados períodos, a atividade fraudulenta pode ser significativamente mais alta, o que requer investigação detalhada.
4. ****Distribuição Temporal****: A análise temporal da coluna 'Time' pode revelar padrões, como picos de fraudes em horários específicos do dia ou dias da semana, que podem ser explorados para identificar comportamentos fraudulentos.
5. ****Análise por Intervalos de Tempo****: Dividir o tempo em intervalos (por exemplo, horas ou dias) pode ajudar a identificar se há horários de maior incidência de fraudes. Por exemplo, se 10% das fraudes ocorrerem em um intervalo de 1 hora, isso pode indicar um padrão de comportamento.
6. ****Comparação com Dados Anteriores****: Em análises anteriores, padrões temporais semelhantes foram observados, onde picos de fraudes ocorreram em horários de maior atividade comercial, como durante promoções ou feriados.
7. ****Impacto da Temporalidade****: A análise de como a taxa de fraude varia ao longo do tempo pode ajudar a ajustar os modelos de detecção de fraudes, permitindo que eles sejam mais sensíveis a períodos de maior risco.
8. ****Visualização de Tendências****: A criação de gráficos de linha ou heatmaps pode facilitar a visualização das flutuações na taxa de fraude ao longo do tempo, permitindo uma interpretação mais clara dos dados.
9. ****Ações Recomendadas****: Recomenda-se monitorar continuamente a taxa de fraude em relação ao

tempo e ajustar as estratégias de prevenção de fraudes durante os períodos identificados como de maior risco.


10. **Análise de Causa Raiz**: Investigar as causas dos picos de fraude em determinados períodos pode ajudar a entender se estão relacionados a eventos externos, como campanhas de marketing ou mudanças no comportamento do consumidor.

11. **Integração com Outras Variáveis**: Considerar a interação entre a coluna 'Time' e outras variáveis numéricas (como V1, V2, etc.) pode revelar insights adicionais sobre como diferentes fatores influenciam a ocorrência de fraudes.

12. **Documentação e Relatórios**: Manter um registro detalhado das análises temporais e suas implicações para futuras referências, além de relatar os achados para as partes interessadas, pode ajudar na melhoria contínua das práticas de detecção de fraudes.

Métricas calculadas (baseadas no CSV)

```
{
"media_taxa_fraude": 0.002822025634599635,
"pico_taxa_fraude": 0.05853658536585366
}
```



3. Pergunta

Quais as correlações entre variáveis V1-V5 e 'Class'?

Tipo de análise: corr — Pedido de correlação/heatmap (incluindo com Class).

Colunas usadas: V1, V5, Class

Insights

Aqui estão os pontos sobre as correlações entre as variáveis V1, V5 e a classe de fraude ('Class') no dataset:

1. ****Total de Linhas****: O dataset possui 284.807 transações, com apenas 492 (0,17%) classificadas como fraudulentas, resultando em uma taxa de fraude de 0,0017.
2. ****Correlação V1-Class****: A correlação entre V1 e 'Class' é de aproximadamente 0,1013, indicando uma relação positiva fraca. Isso sugere que, à medida que os valores de V1 aumentam, a probabilidade de uma transação ser fraudulenta também tende a aumentar.
3. ****Correlação V5-Class****: A correlação entre V5 e 'Class' é de cerca de 0,0950, também indicando uma relação positiva fraca. Assim como em V1, um aumento nos valores de V5 está associado a uma leve elevação na probabilidade de fraude.
4. ****Correlação entre V1 e V5****: A correlação entre V1 e V5 é praticamente nula ($1,81e-17$), sugerindo que não há uma relação linear significativa entre essas duas variáveis. Isso pode indicar que elas capturam diferentes aspectos do comportamento das transações.
5. ****Interpretação das Correlações****: Embora as correlações sejam fracas, elas ainda podem ser relevantes para a modelagem preditiva. Variáveis com correlações positivas, mesmo que baixas, podem contribuir para a identificação de padrões de fraude quando combinadas com outras variáveis.
6. ****Comparação com Dados Anteriores****: Em análises anteriores, correlações semelhantes foram observadas em outros datasets, onde variáveis numéricas apresentaram correlações fracas com a classe de fraude, mas ainda assim foram úteis em modelos de machine learning.
7. ****Impacto das Correlações****: A presença de correlações fracas sugere que, embora V1 e V5 possam não ser os melhores preditores isoladamente, sua inclusão em um modelo mais complexo pode melhorar a detecção de fraudes.
8. ****Visualização das Correlações****: A criação de um heatmap pode ajudar a visualizar as correlações entre V1, V5 e 'Class', facilitando a identificação de padrões e relações entre as variáveis.
9. ****Ações Recomendadas****: Recomenda-se explorar a interação entre V1 e V5 em modelos de

machine learning, como regressão logística ou árvores de decisão, para verificar se a combinação dessas variáveis pode melhorar a detecção de fraudes.

10. ****Análise de Outras Variáveis****: Considerar a inclusão de outras variáveis numéricas do dataset na análise de correlação pode revelar insights adicionais sobre a relação entre as características das transações e a ocorrência de fraudes.


11. ****Monitoramento Contínuo****: É importante monitorar continuamente as correlações e a eficácia dos modelos de detecção de fraudes, ajustando as variáveis utilizadas conforme novos dados se tornam disponíveis.

12. ****Documentação e Relatórios****: Manter um registro detalhado das correlações e suas implicações para futuras análises e relatórios pode ajudar na melhoria contínua das práticas de detecção de fraudes.

Métricas calculadas (baseadas no CSV)

```
{
  "top_correlacoes": [
    [
      "V1",
      "Class",
      0.10134729859508294
    ],
    [
      "Class",
      "V1",
      0.10134729859508294
    ],
    [
      "V5",
      "Class",
      0.09497429899144802
    ],
    [
      "Class",
      "V5",
      0.09497429899144802
    ],
    [
      "V1",
      "V5",
      1.8126116695596912e-17
    ]
  ]
}
```

```
],
"correl_com_Class_top5": [
[
"V1",
0.10134729859508294
],
[
"V5",
0.09497429899144802
]
]
}
```



4. Pergunta

Detecte outliers em 'Amount' e sugira remoção.

Tipo de análise: box — Pedido de outliers/anomalias.

Colunas usadas: Amount

Insights

Aqui estão os pontos sobre a detecção de outliers na coluna 'Amount' do dataset, com base nas informações fornecidas:

1. ****Total de Linhas****: O dataset contém 284.807 transações, das quais 31.904 (aproximadamente 11,2%) foram identificadas como outliers na coluna 'Amount'.
2. ****Taxa de Fraude****: A taxa de fraudes no dataset é de 0,17% (492 fraudes em 284.807 transações), indicando que a maioria das transações (99,83%) é legítima. A presença de outliers em 'Amount' pode estar relacionada a transações fraudulentas.
3. ****Identificação de Outliers****: Os outliers em 'Amount' foram identificados utilizando o método do boxplot, que considera valores que estão além de 1,5 vezes o intervalo interquartil (IQR) como outliers. Isso sugere que os valores extremos podem distorcer a análise.
4. ****Distribuição de 'Amount'****: A análise da distribuição de 'Amount' mostra que a maioria dos valores está concentrada em uma faixa específica, enquanto os outliers se afastam significativamente dessa faixa, indicando possíveis anomalias que merecem investigação.
5. ****Comparação com Dados Anteriores****: Em análises anteriores, a detecção de outliers em colunas numéricas similares resultou em taxas de outliers variando entre 5% a 15%, sugerindo que a coluna 'Amount' apresenta uma quantidade considerável de outliers, o que é consistente com padrões observados.
6. ****Impacto dos Outliers****: A presença de 31.904 outliers pode impactar negativamente modelos preditivos, pois eles podem distorcer a média e a variância, levando a decisões erradas em relação à detecção de fraudes.
7. ****Análise de Tendências****: A análise temporal (coluna 'Time') pode ser realizada para verificar se os outliers em 'Amount' estão concentrados em períodos específicos, o que pode indicar padrões de comportamento fraudulentos.
8. ****Ações Recomendadas****: Recomenda-se investigar os outliers identificados em 'Amount' para entender se são transações fraudulentas ou se representam comportamentos legítimos, a fim de ajustar os modelos de detecção de fraudes.
9. ****Visualização****: A visualização em boxplot da coluna 'Amount' pode ajudar a ilustrar a

distribuição dos dados e a localização dos outliers, facilitando a comunicação dos resultados para as partes interessadas.


10. **Próximos Passos**: Considerar a aplicação de técnicas de machine learning, como Isolation Forest ou DBSCAN, para uma análise mais robusta dos outliers e sua relação com a classe de fraude.

11. **Validação Cruzada**: Realizar validação cruzada com outros conjuntos de dados para verificar a consistência dos outliers identificados e sua relação com fraudes conhecidas.

12. **Documentação**: Manter um registro detalhado das análises de outliers e suas implicações para futuras referências e para a melhoria contínua dos processos de detecção de fraudes.

Métricas calculadas (baseadas no CSV)

```
{
  "colunas": [
    "Amount"
  ],
  "outliers_por_coluna": {
    "Amount": 31904
  }
}
```



5. Pergunta

Quais conclusões gerais sobre fraudes no dataset?

Tipo de análise: class_summary — Pedido focado em fraude/Class.

Colunas usadas: Class, Amount

Insights

Aqui estão as conclusões gerais sobre fraudes no dataset, com base nas métricas e no contexto fornecido:

1. ****Total de Transações****: O dataset contém 284.807 transações, das quais apenas 492 (0,17%) são classificadas como fraudulentas, resultando em uma taxa de fraude de 0,0017. Isso indica que a grande maioria das transações é legítima.
2. ****Desbalanceamento de Classes****: A classe de transações fraudulentas (1) representa apenas 0,17% do total, enquanto as transações legítimas (0) correspondem a 99,83%. Esse desbalanceamento (0,0017) pode dificultar a eficácia dos modelos de detecção de fraudes.
3. ****Média do Valor das Transações****: O valor médio das transações para a classe legítima (0) é de aproximadamente R\$ 88,29, enquanto para a classe fraudulenta (1) é de R\$ 122,21. Isso sugere que as transações fraudulentas tendem a ser de maior valor.
4. ****Comparação de Valores****: A diferença de R\$ 33,92 entre os valores médios das transações legítimas e fraudulentas pode indicar que transações de maior valor têm maior probabilidade de serem fraudulentas, o que merece investigação adicional.
5. ****Total de Fraudes****: Com 492 fraudes identificadas, é crucial focar em estratégias de detecção que priorizem essas transações, dado que representam uma fração muito pequena do total, mas podem ter um impacto financeiro significativo.
6. ****Análise de Outliers****: A presença de outliers na coluna 'Amount' deve ser considerada, pois 31.904 transações (aproximadamente 11,2%) foram identificadas como outliers. Esses valores extremos podem distorcer a análise e a modelagem preditiva.
7. ****Impacto dos Outliers****: A presença de outliers pode afetar negativamente a média e a variância dos dados, levando a decisões erradas na detecção de fraudes. É recomendável investigar esses outliers para determinar se são transações fraudulentas ou legítimas.
8. ****Padrões Temporais****: A análise temporal da coluna 'Time' pode revelar padrões de comportamento fraudulentos, como picos de fraudes em horários ou dias específicos, que podem ser explorados para melhorar a detecção.
9. ****Correlação com Variáveis****: As correlações entre as variáveis V1 e V5 com a classe de

fraude são fracas (aproximadamente 0,10), mas ainda podem ser relevantes para a modelagem preditiva. A inclusão dessas variáveis em modelos mais complexos pode melhorar a detecção de fraudes.

10. **Recomendações de Ação**: É recomendável investigar as transações identificadas como fraudulentas e os outliers, além de ajustar os modelos de detecção de fraudes para considerar a temporalidade e os valores das transações.

11. **Visualizações**: A criação de visualizações, como boxplots e heatmaps, pode ajudar a ilustrar a distribuição dos dados e as correlações, facilitando a comunicação dos resultados para as partes interessadas.

12. **Documentação e Monitoramento**: Manter um registro detalhado das análises e suas implicações é fundamental para a melhoria contínua dos processos de detecção de fraudes e para a adaptação a novos padrões de comportamento.

Métricas calculadas (baseadas no CSV)

```
{
  "taxa_fraude": 0.001727485630620034,
  "total_fraudes": 492,
  "desbalanceamento": 0.00173047500131896,
  "amount_medio_por_classe": {
    "0": 88.29102242231328,
    "1": 122.21132113821139
  }
}
```

